

I. Pen-and-paper

1) Answer 1

$$\phi_j(x) = \|x\|_2^j \quad f(x, w) = \sum_{j=0}^3 w_j \cdot \phi_j(x)$$

$$w = (\phi^T \cdot \phi)^{-1} \cdot \phi^T \cdot z$$

$$\phi = \begin{bmatrix} 1 & \sqrt{2} & 2 & (\sqrt{2})^3 \\ 1 & \sqrt{2} & 2 & (\sqrt{2})^3 \\ 1 & \sqrt{2} & 2 & (\sqrt{2})^3 \\ 1 & \sqrt{2} & 2 & (\sqrt{2})^3 \\ 1 & \sqrt{2} & 2 & (\sqrt{2})^3 \\ 1 & \sqrt{2} & 2 & (\sqrt{2})^3 \\ 1 & \sqrt{2} & 2 & (\sqrt{2})^3 \\ 1 & \sqrt{2} & 2 & (\sqrt{2})^3 \end{bmatrix} \quad \begin{aligned} \phi_1(x_1) &= (\sqrt{1^2+1^2+0^2})^1 = \sqrt{2} \\ \phi_1(x_2) &= (\sqrt{1^2+1^2+5^2})^1 = \sqrt{27} \\ \phi_1(x_3) &= (\sqrt{0^2+2^2+4^2})^1 = \sqrt{20} \\ \phi_1(x_4) &= (\sqrt{1^2+2^2+3^2})^1 = \sqrt{14} \\ \phi_1(x_5) &= (\sqrt{2^2+0^2+9^2})^1 = \sqrt{85} \\ \phi_1(x_6) &= (\sqrt{1^2+1^2+1^2})^1 = \sqrt{3} \\ \phi_1(x_7) &= (\sqrt{2^2+0^2+2^2})^1 = \sqrt{8} \\ \phi_1(x_8) &= (\sqrt{0^2+2^2+9^2})^1 = \sqrt{85} \end{aligned}$$

$$\phi^T = \begin{bmatrix} 1 & 1 & 1 & 1 & 1 & 1 & 1 & 1 \\ \sqrt{2} & \sqrt{2} & \sqrt{2} & \sqrt{2} & \sqrt{2} & \sqrt{2} & \sqrt{2} & \sqrt{2} \\ 2 & 2 & 2 & 2 & 2 & 2 & 2 & 2 \\ (\sqrt{2})^3 & (\sqrt{2})^3 & (\sqrt{2})^3 & (\sqrt{2})^3 & (\sqrt{2})^3 & (\sqrt{2})^3 & (\sqrt{2})^3 & (\sqrt{2})^3 \end{bmatrix}$$

$$z = \begin{bmatrix} 1 \\ 3 \\ 2 \\ 0 \\ 6 \\ 4 \\ 5 \\ 7 \end{bmatrix} \quad \text{Utilizamos ferramentas computacionais para o cálculo de matrizes e chegamos a}$$

$$w = \begin{bmatrix} 4,594 \\ -1,696 \\ 0,340 \\ -0,013 \end{bmatrix}$$

$$f(x, w) = 4,594 + (-1,696) \cdot \|x\| + 0,340 \cdot \|x\|^2 - 0,013 \|x\|^3$$

2) Answer 2

②

$$RMSE = \sqrt{\frac{\sum_{i=1}^n (\text{Predicted}_i - \text{Observed}_i)^2}{n}}$$

$$f(x_9, w) = 4,594 - 1,696 \cdot \sqrt{2} + 0,340 \cdot 2 - 0,013 (\sqrt{2})^3 =$$

$$(\|x_9\| = \sqrt{2}) = 2,833$$

$$f(x_{10}, w) = 4,594 - 1,696 \cdot \sqrt{6} + 0,340 \cdot 6 - 0,013 (\sqrt{6})^3 =$$

$$(\|x_{10}\| = \sqrt{6}) = 2,289$$

$$RMSE = \sqrt{\frac{(2,833 - 2)^2 + (2,289 - 4)^2}{2}}$$

$$= 1,347$$

3) Answer 3

③ Considerando a binarização e classificações "P" e "N" transformamos os dados para o seguinte formato:

	Y_1	Y_2	Y_3	output
x_1	1	1	0	N
x_2	1	1	1	N
x_3	0	2	1	N
x_4	1	2	0	N
x_5	2	0	1	P
x_6	1	1	0	P
x_7	2	0	0	P
x_8	0	2	1	P

Para descobirmos a "root" da árvore vamos calcular a entropia e ganho de informação dos atributos:

$$E(Y_1=0) = -\frac{1}{2} \log_2\left(\frac{1}{2}\right) - \frac{1}{2} \log_2\left(\frac{1}{2}\right) = 1$$

$$E(Y_1=1) = -\frac{1}{4} \log_2\left(\frac{1}{4}\right) - \frac{3}{4} \log_2\left(\frac{3}{4}\right) = 0,811$$

$$E(Y_1=2) = -\frac{2}{2} \log_2\left(\frac{2}{2}\right) = 0$$

$$E(Y_2=0) = -\frac{2}{2} \log_2\left(\frac{2}{2}\right) = 0$$

$$E(Y_2=1) = -\frac{1}{3} \log_2\left(\frac{1}{3}\right) - \frac{2}{3} \log_2\left(\frac{2}{3}\right) = 0,918$$

$$E(Y_2=2) = -\frac{1}{3} \log_2\left(\frac{1}{3}\right) - \frac{2}{3} \log_2\left(\frac{2}{3}\right) = 0,918$$

$$E(Y_3=0) = -\frac{4}{8} \log_2\left(\frac{4}{8}\right) - \frac{4}{8} \log_2\left(\frac{4}{8}\right) = 1$$

$$E(Y_3=1) = -\frac{4}{8} \log_2\left(\frac{4}{8}\right) - \frac{4}{8} \log_2\left(\frac{4}{8}\right) = 1$$

$$E(\text{total}) = -\frac{4}{8} \log_2\left(\frac{4}{8}\right) - \frac{4}{8} \log_2\left(\frac{4}{8}\right) = 1$$

$$\text{Gain}(\text{Output}, Y_1) = E(\text{total}) - \sum [p(\text{output}|Y_1) \cdot E(\text{output}|Y_1)]$$

$$= 1 - \left(\frac{2}{8} \cdot 1 + \frac{4}{8} \cdot 0,811 + \frac{2}{8} \cdot 0\right) = 0,3445$$

$$\text{Gain}(\text{Output}, Y_2) = 1 - \left(\frac{2}{8} \cdot 0 + \frac{3}{8} \cdot 0,918 + \frac{3}{8} \cdot 0,918\right) = 0,3115$$

$$\text{Gain}(\text{Output}, Y_3) = 1 - \left(\frac{1}{2} \cdot 1 + \frac{1}{2} \cdot 1\right) = 0$$

Y_1 é o atributo com maior ganho de informação, então será a root da árvore:



Vamos repetir o processo fixando Y_1 (omitindo valores que não estão no set de treino)

$$E(Y_2=2|Y_1=0) = -\frac{1}{2} \log_2\left(\frac{1}{2}\right) - \frac{1}{2} \log_2\left(\frac{1}{2}\right) = 1$$

$$E(Y_3=1|Y_1=0) = -\frac{1}{2} \log_2\left(\frac{1}{2}\right) - \frac{1}{2} \log_2\left(\frac{1}{2}\right) = 1$$


~~Como os valores de~~

$$\text{Gain}(Y_1=0, Y_2) = 1 - \left(\frac{2}{2} \cdot 1\right) = 0$$

$$\text{Gain}(Y_1=0, Y_3) = 1 - \left(\frac{2}{2} \cdot 1\right) = 0$$

Como Y_2 e Y_3 têm o mesmo ganho, podemos optar por qualquer um destes atributos, vamos optar por Y_2 de forma aleatória.

Aprendizagem 2021/22
Homework II – Group 114




Vamos calcular para $Y_1=2$:


$$E(Y_2=0 | Y_1=2) = -\frac{1}{4} \log_2\left(\frac{1}{4}\right) = 0$$

$$E(Y_3=1 | Y_1=2) = -\frac{1}{4} \log_2\left(\frac{1}{4}\right) = 0$$

O Ganho também é igual entre os atributos, desta vez escolhemos Y_2 :



4) Answer 4



~~(2,0,2)~~ $(0,1,2)$ é indefinido, pois, tem classificações N e P

Vamos calcular agora para $Y_1=1$:

$$E(Y_3=0 | Y_1=1) = -\frac{1}{3} \log_2\left(\frac{1}{3}\right) - \frac{2}{3} \log_2\left(\frac{2}{3}\right) = 0,918$$

$$E(Y_3=1 | Y_1=1) = 0 - \frac{1}{1} \log_2\left(\frac{1}{1}\right) = 0$$

$$E(Y_2=1 | Y_1=1) = -\frac{1}{3} \log_2\left(\frac{1}{3}\right) - \frac{2}{3} \log_2\left(\frac{2}{3}\right) = 0,918$$

$$E(Y_2=2 | Y_1=1) = 0 - \frac{1}{1} \log_2\left(\frac{1}{1}\right) = 0$$

$$\text{Gain}(Y_1=1, Y_2) = 1 - \left(\frac{2}{4} \cdot 0,918 + \frac{3}{4} \cdot 0,918 + \frac{1}{4} \cdot 0\right)$$

$$\text{Gain}(Y_1=1, Y_3) = 1 - \left(\frac{3}{4} \cdot 0,918 + \frac{1}{4} \cdot 0\right)$$



Mais uma vez Y_2 e Y_3 têm o mesmo ganho. Desta vez selecionamos Y_3 .

④ Assumindo os valores não representados na árvore como indefinidos quando computamos $(2,0,0)$ obtemos indefinido e quando computamos $(1,2,1) = (1,2,0)$ obtemos "N". Portanto Em termos de "accuracy" significa 0%.

II. Programming and critical analysis

5) Answer 5

a. number of selected features in {1,3,5,9} b .maximum tree depth in {1,3,5,9}



6) Answer 6

A correlação observada demonstra que há features que dependem de outras features, estando por vezes associadas/ligadas. Por exemplo, se escolhermos 3 features vamos ter um score muito melhor que se escolhermos 5, devendo-se ao facto de encontrar facilmente 3 features que dependam simultaneamente umas das outras, não sendo o mesmo para 5 features.

Quanto mais profunda for a árvore, mais “ramos” vão surgir, aumentando o erro, e torna a árvore menos eficaz. No caso em que surgem mais folhas pode levar a casos em que seja detetado múltiplas classificações erradas ou indefinidas.

7) Answer 7

A depth = 3 é a escolhida com base na accuracy do conjunto de treino e de teste, visto que diminui a probabilidade de overfitting e consequentemente aumenta a accuracy. Uma escolha do depth com valores de extremo (1 ou 9) aumenta o erro no conjunto de teste e de treino. Ainda assim a amostra de dados não justifica a escolha de um depth máximo.

III. APPENDIX

```
import pandas as pd
import numpy as np
from scipy.io.arff.arffread import print_attribute
from sklearn import tree
from scipy.io.arff import loadarff
from sklearn.tree import DecisionTreeClassifier
from sklearn.model_selection import train_test_split
from sklearn import metrics
import matplotlib.pyplot as plt
import seaborn as sns

if __name__ == '__main__':
    raw_data = loadarff('breast.w.arff')
    df_data = pd.DataFrame(raw_data[0])
    classe = df_data.pop('Class')
    df_data = df_data.astype(int)
    Y = classe.str.decode('utf-8')
    for v in range(0,683):
        if Y.loc(axis=0)[v] == 'benign':
            Y.loc(axis=0)[v] = 1
        else:
            Y.loc(axis=0)[v] = 0

    Y = np.array(Y)
    X_train, X_test, y_train, y_test = train_test_split(df_data,Y, test_size=0.30)

#Exercise 5 i
for i in [1,3,5,9]:
    tre = DecisionTreeClassifier(criterion = 'entropy',max_features=i)
    y_train = y_train.astype('int')
    y_test = y_test.astype('int')
    tre.fit(X_train,y_train)
    p=tre.score(X_train, y_train).round(2)
    j=tre.score(X_test, y_test).round(2)
    print("Train : %0.3f Test : %.3f Dif : %0.3f" % (p,j, p-j))

#Exercise 5 ii
for i in [1,3,5,9]:
    tre = DecisionTreeClassifier(max_depth=i)
    y_train = y_train.astype('int')
    y_test = y_test.astype('int')
    tre.fit(X_train,y_train)
    p=tre.score(X_train, y_train).round(2)
    j=tre.score(X_test, y_test).round(2)
    print("Train : %0.3f Test : %.3f Dif : %0.3f" % (p,j, p-j))
```

END